

Mestrado em Ciência de Dados

Integração de Dados

Enunciado do Projeto

Introdução

Atualmente as organizações são confrontadas com grandes volumes de dados provenientes de diversas fontes, internas ou externas à organização, e em que os dados podem apresentar formatos distintos. Reconhecer valor nestes dados, identificar possibilidades de integração e de análise por forma a extrair informação e conhecimento a partir dos dados é atualmente um processo fundamental e crucial para a tomada de decisões atempadas e acertadas nas organizações.

O processo de integração de dados envolve a recolha e a extração de dados a partir de diversas fontes, a limpeza e transformação desses dados e a sua integração e armazenamento num repositório de dados que permita ter uma visão unificada dos dados e que possibilite a aplicação de várias técnicas de análise de dados.

Objetivos do Projeto

No âmbito do Projeto da unidade curricular de Integração de Dados pretende-se numa primeira fase, efetuar um estudo bibliográfico sobre o processo de integração de dados e sobre tecnologias e ferramentas de suporte ao mesmo.

Na segunda fase do Projeto, deverá ser implementado este processo. Para tal deverão ser consideradas várias fontes de dados, com diversos formatos e deverão ser utilizadas ferramentas e tecnologias de suporte adequadas, à limpeza e transformação dos dados e ao seu armazenamento num repositório de dados. Posteriormente deverão ser aplicadas algumas técnicas que permitam efetuar a análise de dados.

O projeto deverá ser desenvolvido em grupo (máximo 3 estudantes que devem pertencer ao mesmo turno). Encontra-se no Moodle um formulário para a indicação dos grupos de estudantes.

Descrição do Projeto

Na primeira fase, pretende-se a realização de um estudo bibliográfico sobre o processo de integração de dados e sobre três tecnologias ou plataformas de suporte ao processo, efetuando um estudo comparativo.

Na segunda fase, pretende-se resolver um problema de integração de dados, construir um *dataset* final e efetuar a sua análise.

O problema e as respetivas fontes de dados podem ser identificados pelo grupo, no âmbito de um contexto laboral, ou, em alternativa, pode ser utilizado um problema e fontes de dados públicas. Também poderão criar um cenário imaginário gerando dados.

As fontes de dados a utilizar devem ter pelo menos quatro origens e formatos distintos. Poderão, entre outros, utilizar como origem ficheiros CSV, XLS, JSON, XML e/ou bases de dados relacionais como, por exemplo, MySQL, Oracle, MSAccess, SQL Server, PostgreSQL.

Devem ser utilizadas ferramentas que permitam a implementação do processo de integração de dados e dos processos que envolvam a extração, limpeza, transformação, carregamento e armazenamento.

Deverá ser criado um *dataset* final para posterior análise. Este *dataset* deverá ser armazenado num formato adequado e que possibilite a sua posterior análise através de uma ferramenta de análise de dados.

O processo de análise de dados deve ser suportado por um conjunto de painéis (*dashboards*) e outros indicadores que permitam responder a diversas questões de negócio relativas ao cenário/problema e que permitam obter conhecimento sobre o mesmo. Este conhecimento deve suportar a tomada de decisões.

Relatório

Escrita de um relatório que documente as atividades realizadas na primeira fase e na segunda fase.

Na primeira fase devem ser abordados os seguintes aspetos:

- a. Enquadramento do processo de integração de dados, os seus objetivos; principais características e implementação nas organizações.
- b. Estudo e seleção de um conjunto de 3 tecnologias ou plataformas de suporte ao processo de integração de dados disponíveis no mercado e realização de um estudo comparativo. O estudo poderá abordar os seguintes aspetos: gratuidade, usabilidade, características, funcionalidades, abrangência no acesso a fontes de dados, infraestruturas tecnológicas de suporte.

Na segunda fase devem ser abordados os seguintes aspetos:

- a. Descrição do cenário, problema a resolver e dos objetivos a atingir.
- b. Descrição das ferramentas utilizadas.

- c. Descrição das características de todas as fontes originais de dados (proveniência, formato, principais atributos e suas propriedades).
- d. Descrição dos acessos às fontes de dados acima identificadas indicando as configurações das ligações estabelecidas.
- e. Descrição de todos os processos envolvidos na integração de dados (extração, limpeza, transformação, carregamento e armazenamento).
- f. Descrição do *dataset* final e dos seus atributos.
- g. Descrição do processo de análise de dados onde devem identificar as questões a responder e apresentar as respetivas respostas, bem como o conhecimento obtido.

O relatório (formato .doc e .pdf) e todos os ficheiros associados ao desenvolvimento do projeto devem ser entregues na plataforma Moodle, nas datas definidas no calendário de avaliação.

O relatório pode ser escrito em formato de artigo, podendo ser adotado, o modelo disponibilizado pelo IEEE:

<https://www.ieee.org/conferences/publishing/templates.html>

Prova Oral

A prova oral é composta por uma apresentação deve ser acompanhada por um conjunto de slides (.ppt) que reflitam todo o trabalho desenvolvido. A prova oral é presencial e deverá ser realizada obrigatoriamente por todos os elementos do grupo na data definida no calendário de avaliação. A não presença de um elemento do grupo nesta prova, implica a classificação de zero valores para esse elemento do grupo no projeto e na prova oral. A prova oral consiste também na colocação de questões sobre o projeto desenvolvido a que o estudante deve responder.

Critérios de avaliação do Projeto

Estudo bibliográfico e comparativo	15%
Cenário/Problema/objetivos/ferramentas	10%
Fontes de Dados	10%
Processo de Integração de dados e construção do <i>dataset</i>	40%
Processo de análise de dados	20%
Estrutura e forma Relatório/Artigo	5%

Classificação Final do Projeto (60%)

A nota final do projeto será atribuída com base na seguinte fórmula:

$$\textbf{\underline{Nota Final do Projeto} = 60\% * Projeto * 100\% Prova Oral}$$

(A prova oral é obrigatória e tem mínimos de 10 valores)
(O projeto tem mínimos de 10 valores)

Informação adicional

Ferramentas/plataformas de integração de dados - Exemplos:

No motor de busca (ex.: Google) pesquisar por “data integration tools” ou “ferramentas de integração de dados”. Alguns fabricantes de ferramentas podem ser consultados a partir do *Magic Quadrant* da *Gartner*.

Figure 1: Magic Quadrant for Data Integration Tools



Gartner

Figura 1 – Quadrante Mágico da Gartner para ferramentas de integração de dados

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



Gartner.

Figura 2 – Quadrante Mágico da Gartner para análise de dados e *business intelligence*

Fontes de dados – Exemplos

- <https://datasetsearch.research.google.com> (permite a procura de *datasets*)
- <https://www.kdnuggets.com/datasets/index.html> (dados para a ciência dos dados)
- www.kaggle.com/DataSets (dados para a ciência dos dados)
- <https://archive.ics.uci.edu/ml/index.php> (dados para a ciência dos dados)

- [Datasets - Weka Wiki \(waikato.github.io\)](https://waikato.github.io) (dados para a ciência dos dados)
- [Mendeley Data](#) (*datasets* vários)
- www.pordata.pt (dados sobre Municípios, Portugal e a Europa)
- www.who.int (dados de saúde a nível mundial)
- <https://dados.gov.br/dataset> (*datasets* governamentais)
- [Data Science for Social Good Portugal · GitHub](#) (*datasets* de áreas sociais portuguesas)
- [GitHub: Let's build from here · GitHub](#) (pesquisar por *datasets*)
- <https://worlddata.ai/> (dados de várias proveniências)
- [Explore — E-REDES](#) (dados sobre produção/consumo energético)
- www.ctt.pt (dados sobre regiões administrativas e códigos postais)